

ТЕСТУВАННЯ, ДОСЛІДЖЕННЯ ТА АНАЛІЗ ОСНОВНИХ АЛГОРИТМІВ КЛАСТЕРИЗАЦІЇ НАБОРІВ ЧИСЛОВИХ ДАНИХ

Завдання для самостійної (лабораторної) роботи

1. Обрати для аналізу 3-4 достатньо різні алгоритми кластеризації (за бажанням виконавця число алгоритмів можна збільшити). Узгодити вибір алгоритмів з колегами так, щоб у різних виконавців було не більше 1-2 спільних тем.

2. Порівняти результати роботи цих алгоритмів на різних наборах даних.

Набори даних формуються виконавцем:

- детерміновано
- стохастично (із застосуванням різних датчиків випадкових чисел)
- за можливістю – використати реальні набори даних.

Набори даних розподіляються на різні типи залежно від форми майбутніх кластерів.

Способи формування наборів даних або типів наборів даних можуть бути, наприклад, такими.

Кожному кластеру відповідає:

1) коло (куля, багатовимірна куля) певного радіусу, яке містить усі точки цього кластера;

2) еліпс (багатовимірний еліпс);

– осі всіх еліпсів взаємно паралельні;

– "—" "—" "—" непаралельні.

3) квадрат (куб, багатовимірний куб)

– сторони всіх квадратів взаємно паралельні;

– "—" "—" "—" непаралельні.

4) прямокутник (паралелепіпед, багатовимірний паралелепіпед)

– сторони всіх прямокутників взаємно паралельні;

– "—" "—" "—" непаралельні.

5) різні несиметричні утворення (сукупності точок), наприклад, подібні до літер Г, С, П, Т, Е, Х та ін.

6) різні суміші попередніх типів;

7) інші варіанти (на вибір виконавця), можливість виявити свою фантазію та дослідницьку здібність.

3. Дослідити обрані алгоритми на "неперервність" (або стабільність):

Реалізуючи певний алгоритм А для певного обраного набору даних Д, зробити δ -зміну цього набору Д, перемістивши одну з точок набору Д на " δ -невелику" відстань.

Застосувати повторно алгоритм А для δ -модифікованого набору Д'. З'ясувати, чи зміняться результати кластеризації, і якщо зміняться, то наскільки істотно.

Повторити цю процедуру для різних точок (наборів точок) і різних значень δ .

4. На всіх етапах застосовувати різні методи візуалізації початкового набору даних, проміжних та остаточних результатів кластеризації.

5. Визначати та порівнювати час та необхідний об'єм пам'яті для кожної реалізації.

6. Написати звіт, який повинен містити:

- детальні змістовні описи обраних для аналізу алгоритмів;
- таблиці й діаграми, в яких зібрано результати дослідження;
- висновки та рекомендації щодо застосування досліджених алгоритмів;
- список джерел, використаних для виконання роботи.

Максимальна оцінка за лабораторну роботу – 60 модульних балів.